

SKILLNAV

Observatoire des compétences IA et Data Science

Guide de modélisation

Volet Structure Mining

Module M242 — Analyse de Web

École Nationale des Sciences Appliquées de Tétouan

Encadrement : Pr. Imad Sassi

1. Ce que « modélisation » veut dire dans M242

On pourrait croire que « modélisation » signifie ML supervisé (régression, classification). Ce n'est pas le cas dans le contexte du sujet imposé. M242 attend trois choses, alignées sur les trois axes Web Mining.

Axe Web Mining	Type de modélisation attendu	Responsable
Content Mining	NER comparatif (BERT multilingue, CamemBERT, DistilBERT) pour l'extraction des compétences à partir du texte brut	Karamo Sylla
Structure Mining	Modélisation en graphe (nœuds Job / Skill / Company + arêtes), puis algorithmes de communautés (Louvain, Leiden, Label Propagation, PageRank)	Bachirou Konaté
Usage Mining	Forecasting temporel (ARIMA, Prophet, LSTM) sur les compétences émergentes	Bachirou Konaté

S'y ajoute la modélisation NoSQL polyglotte du PRD §7 : MongoDB (source of truth) + Neo4j (graphe) + Elasticsearch (recherche). Il s'agit de modélisation de schéma, et non de machine learning. Cette partie reste pilotée par Karamo Sylla.

Conclusion : la part de Bachirou Konaté couvre désormais deux axes. D'une part la construction du graphe Skill $\leftrightarrow$ Job dans Neo4j puis l'exécution comparative de quatre algorithmes de communautés (§N2.2 du PRD). D'autre part le forecasting temporel des compétences émergentes (§N2.3 du PRD) via ARIMA, Prophet et LSTM. Ces deux volets constituent l'essentiel du Sprint 2 et du Sprint 3.

2. Qui fait quoi (RACI, focus modélisation)

Tâche de modélisation	Karamo Sylla	Bachirou Konaté
Schémas Pydantic (skillnav/schemas/)	Responsable	Consulté
Insertion MongoDB Atlas	Responsable	Informé
Construction du graphe Neo4j	Consulté	Responsable
Algorithmes de communautés (Louvain, Leiden, ...)	Informé	Responsable
Tableau comparatif §N2.2	Informé	Responsable
NER comparatif (§N2.1)	Responsable	Consulté
Forecasting Usage Mining (§N2.3)	Informé	Responsable
Indexation Elasticsearch	Responsable	Informé

La responsabilité immédiate côté Karamo Sylla consiste à préparer le terrain afin que Bachirou Konaté puisse attaquer le volet Structure Mining sans friction.

3. Format de données : pourquoi le faire évoluer

Le format YAML actuel reste parfait pour l'EDA — c'est-à-dire lisible humainement, ce qui a guidé les deux notebooks existants. Deux limites apparaissent toutefois pour la modélisation.

Limite	Conséquence
3 467 fichiers à parser à chaque chargement	Lent, en particulier dès qu'une itération fréquente est nécessaire (cas typique du graphe)
Pas directement consommable par Neo4j, MongoDB ou Elasticsearch	Risque de mobiliser deux jours d'écriture de parseur du côté Structure Mining

3.1 Approche retenue

Le format YAML d'origine est conservé en tant que source brute. Trois formats dérivés viennent s'ajouter, chacun optimisé pour son usage.

Fichier dérivé	Format	Usage	Consommateur
data/jobs.jsonl	JSON Lines (un job par ligne)	Source unifiée importable d'un seul mongoimport	MongoDB + dashboard backend
data/graph_nodes.csv	CSV (id, type, label, attributs)	Nœuds Neo4j (Job, Skill, Company)	Bachirou Konaté via Neo4j LOAD CSV
data/graph_edges.csv	CSV (source_id, target_id, type, weight)	Arêtes Neo4j (REQUIRES, POSTED_BY)	Bachirou Konaté via Neo4j LOAD CSV

3.2 Justification du choix de format par cible

- Neo4j dispose d'une commande native LOAD CSV qui crée des arêtes en bulk, ce qui constitue le pattern standard pour bootstrapper un graphe à partir d'un dump.
- JSON Lines est le format privilégié de MongoDB et d'Elasticsearch pour l'import bulk.
- Le YAML d'origine reste la source brute, utile à la lecture humaine, à l'audit qualité et au retour aux annonces originales.

4. Plan d'action en trois phases

Phase A : préparation (Karamo Sylla, environ trois heures)

Trois artefacts à produire avant le démarrage du Sprint 2.

Artefact	Contenu
scripts/build_dataset.py	Lit les 3 467 YAML via skillnav_eda.charger_corpus puis écrit data/jobs.jsonl, data/graph_nodes.csv et data/graph_edges.csv

Artefact	Contenu
notebooks/02_graph_starter.ipynb	Template prêt à l'emploi : import skillnav_eda, connexion Neo4j AuraDB, chargement des CSV, exemple Louvain commenté, et trois TODO pour Leiden, Label Propagation et PageRank
docs/MODELISATION_GUIDE.md	Document de référence rappelant l'architecture (Mongo + Neo4j + ES), le schéma du graphe, la procédure de création du compte AuraDB et le tableau comparatif §N2.2 à compléter

Phase B : exécution Structure Mining et Forecasting (Bachirou Konaté, Sprint 2 et 3)

Volet Structure Mining (Sprint 2, J7 à J12).

- Suivre MODELISATION_GUIDE.md pas à pas.
- Lancer 02_graph_starter.ipynb pour peupler le graphe Neo4j.
- Exécuter Louvain, Leiden, Label Propagation et PageRank.
- Comparer les métriques : modularité, nombre de communautés, temps d'exécution, top compétences par communauté.
- Compléter le tableau §N2.2 dans le rapport méthodologique L5.
- Exporter une visualisation du graphe (PNG ou HTML).

Volet Usage Mining — Forecasting (Sprint 3, J13 à J18).

- Construire les séries temporelles de compétences à partir du corpus consolidé.
- Implémenter ARIMA, Prophet et LSTM sur un panel d'au moins dix compétences phares.
- Comparer les performances (MAPE, RMSE, temps d'entraînement) dans le tableau §N2.3.
- Rédiger la section §N2.3 du rapport L5 et exporter les courbes de prévision.

Phase C : travail parallèle (Karamo Sylla, Sprint 2 et 3)

- NER comparatif (§N2.1) sur les descriptions de poste.
- Modélisation NoSQL polyglotte : MongoDB Atlas, Neo4j (mise à disposition), Elasticsearch Cloud.
- Dashboard Next.js — pages /graph et /forecasting alimentées par les modèles produits par Bachirou Konaté.

5. Détail du notebook 02_graph_starter.ipynb

Le notebook livré en Phase A est un starter kit dont le rôle est de préparer l'environnement Neo4j et de servir de patron pour le travail algorithmique. Sa structure est volontairement dichotomique : la moitié technique (connexion, chargement bulk, exemple Louvain commenté) est livrée prête à l'emploi ; l'autre moitié (trois algorithmes restants, interprétation, synthèse §N2.2) constitue le périmètre d'évaluation du volet Structure Mining.

5.1 Cellules livrées clés en main (Phase A)

§	Section du notebook	État
0	Setup : connexion Neo4j AuraDB via .env	Prête à exécuter
1	Vérification des artefacts CSV générés par build_dataset.py	Prête à exécuter
2	Contraintes d'unicité et index Cypher	Prête à exécuter
3	Chargement bulk des 13 071 nœuds (UNWIND par batches de 500)	Prête à exécuter
4	Chargement bulk des 62 341 arêtes (REQUIRES et POSTED_BY)	Prête à exécuter
5	Validation par comptages côté Neo4j	Prête à exécuter
6	Exemple complet : algorithme Louvain (commenté)	Prête à exécuter, sert de patron
9	Fermeture propre du driver Neo4j	Prête à exécuter

5.2 Cellules à compléter en Phase B

§	Section du notebook	Action attendue
7	Leiden	Adapter la requête Cypher (gds.leiden.stream) sur le patron Louvain, mesurer durée et nombre de communautés
7	Label Propagation	Adapter (gds.labelPropagation.stream), même méthode
7	PageRank	Calculer les centralités, extraire le top 20 compétences
8	Tableau comparatif §N2.2	Reporter les métriques des quatre algorithmes (communautés, modularité, temps, notes)

5.3 Logique du découpage

Le travail livré clés en main couvre la plomberie technique : driver Neo4j, gestion des batches, optimisation des transactions, contraintes d'unicité. Cette partie est universelle et ne contribue pas à l'évaluation académique du volet.

Le travail à compléter couvre en revanche le contenu scientifique : choix des paramètres, exécution comparative des trois algorithmes restants, interprétation des résultats et rédaction de la synthèse. C'est ce périmètre qui porte la note §N2.2 du PRD et qui nourrit la section correspondante du rapport méthodologique L5.

6. Décisions à valider avant Phase A

Choix 1 — Profondeur du graphe

Approche	Nœuds	Arêtes	Justification
Minimal	Job + Skill	REQUIRES	Démarrage rapide, suffit pour Louvain de base
Standard (recommandé)	Job + Skill + Company	REQUIRES, POSTED_BY	Permet de répondre à la question « quelle entreprise recrute quelle famille »
Riche	Job + Skill + Company + Source + Mois	REQUIRES, POSTED_BY, FROM_SOURCE, POSTED_AT	Coût en complexité élevé, pertinent seulement pour un graphe temporel

Recommandation : approche Standard. Elle couvre les besoins des quatre algorithmes et laisse une marge pour des analyses bonus.

Choix 2 — Neo4j local ou Neo4j AuraDB

Option	Pour	Contre
Neo4j Desktop local	Pas de quota, pas d'authentification distante	Nécessite une installation locale
AuraDB Free Tier (recommandé)	Aucune installation, accessible partout, démonstration plus professionnelle en soutenance	Limité à 50 000 nœuds (la volumétrie cible est d'environ 5 000)

Recommandation : AuraDB Free Tier. Aligné avec le PRD §7 et avec la démonstration de soutenance.

Une validation du couple « Standard + AuraDB » autorise le lancement immédiat de la Phase A : script de consolidation, notebook template et guide markdown.